

Progetto 1: Segmentazione Clienti e Churn Prediction

Laboratorio di Intelligenza Artificiale - A.A. 2025/2026

Massimo Mantineo

Matricola: 541924

Università degli Studi di Messina

Corso di Laurea in Informatica

Laboratorio di Intelligenza Artificiale

A.A. 2025/2026



Università
degli Studi di
Messina

1. Obiettivi, Dataset e Preprocessing

II Dataset & Obiettivi:

- **Dataset:** Telco Customer Churn (IBM, 7043 clienti, classi sbilanciate 3:1).
- **Obiettivo:** Prevedere l'abbandono dei clienti (*Churn Prediction*) per fidelizzarli.
- **Riproducibilità:** Codice interamente descritto ed eseguibile in `segmentazione_crunch.ipynb`.

Preprocessing dei Dati:

- Imputazione di 11 righe vuote in *TotalCharges* con 0.0 (nuovi clienti con *tenure=0*).
- Rimozione del codice identificativo univoco *customerID*.




Grafico: Chi abbandona (Yes Churn) ha una permanenza bassissima (mediana ≈ 10 mesi).

2. Segmentazione dei Clienti (Clustering k-Means)

Scelta del numero di Cluster (k):

- **Inertia (Gomito):** Flette a $k = 2$ e $k = 3$.
- **Silhouette Score:** Massimo a $k = 2$ (0.2946).





Grafico: Gomito e Silhouette.

Mappa e Profili dei Cluster ($k = 2$):

- **Cluster 0 (Fedeli - Spesa Basso):**
Spesa media 21.08\$, contratti lunghi, tasso di churn 7.40%.
- **Cluster 1 (A Rischio - Spesa Alta):**
Spesa media 76.84\$, contratti mensili, tasso di churn 31.83%.



3. Modelli di Classificazione e Scenari

Tre classificatori con approcci differenti:

1. Regressione Logistica

Baseline lineare:

Mappa il punteggio lineare delle feature in una probabilità tramite la curva **Sigmoidale**.

2. Albero di Decisione

White-Box Model:

Crea regole IF-THEN gerarchiche basate sull'indice di Gini per massimizzare la purezza.

3. Rete Neurale (MLP)

Black-Box Model:

Usa strati nascosti con attivazione non lineare (ReLU) ed ottimizzatore Adam per pattern complessi.

I due scenari sperimentali messi a confronto:

- **Scenario A (Senza Cluster):** Utilizzo delle sole feature originali preelaborate.
- **Scenario B (Con Cluster):** Aggiunta del cluster di appartenenza (0 o 1) come feature per guidare la classificazione.

3.1 Come Funzionano i Modelli? (Concetti Chiave)

Ogni classificatore elabora i dati con una logica differente:

Regressione Logistica

Logica Probabilistica:

- Pesa l'influenza di ciascuna variabile sul rischio di abbandono.
- Mappa le variabili in una probabilità complessiva.
- Classifica come "a rischio" se supera la soglia del 50%.

Albero di Decisione

Logica a Regole (IF-THEN):

- Divide ricorsivamente i dati ponendo domande basate su soglie.
- Cerca lo split che crea i gruppi più omogenei.
- Struttura visiva trasparente e intuitiva per le decisioni.

Rete Neurale (MLP)

Logica Multi-Strato:

- Simula una rete di neuroni organizzata in vari livelli.
- Apprende relazioni non lineari complesse con la ReLU.
- Regola continuamente le connessioni per correggere gli errori.

4. Tabella dei Risultati

Confronto delle performance dei modelli sui due scenari (Senza vs. Con Cluster).

Tabella: Accuratezza, Recall (Richiamo) e AUC su Train e Test.

Modello	Feature Scenario	Accuracy		Recall		AUC	
		Train	Test	Train	Test	Train	Test
Logistic Regression	Senza Cluster	0.8053	0.8062	0.5485	0.5588	0.8492	0.8422
Logistic Regression	Con Cluster	0.8051	0.8055	0.5485	0.5588	0.8492	0.8423
Decision Tree	Senza Cluster	0.8023	0.7942	0.5612	0.5401	0.8476	0.8267
Decision Tree	Con Cluster	0.8023	0.7942	0.5612	0.5401	0.8476	0.8267
Multi-Layer Perceptron (MLP)	Senza Cluster	0.9143	0.7495	0.7813	0.4278	0.9656	0.7844
Multi-Layer Perceptron (MLP)	Con Cluster	0.9104	0.7360	0.9097	0.5829	0.9722	0.7846

- **Risultato Chiave:** L'aggiunta del cluster come feature permette all'MLP di far salire la Recall nel Test set dal 42.78% al 58.29% (+15.51%), migliorando la capacità di intercettare i clienti a rischio.

5. Interpretazione dell'Albero di Decisione

Significato dei Colori:

- **Nodi Blu:** Maggioranza di clienti fedeli (No Churn).
- **Nodi Arancioni:** Maggioranza di clienti a rischio (Yes Churn).
- **Intensità:** Colori più scuri indicano decisioni più nette e omogenee.

Le Regole Principali:

- **1. Contratto Mensile:** Lo split fondamentale. Chi ha un contratto mensile è molto più instabile.
- **2. Tenure (Permanenza):** I clienti recenti (tenure bassa) con contratto mensile sono a rischio critico.
- **3. Servizio Internet:** L'uso di Fibra Ottica è legato a spesa alta e maggior abbandono.




Grafico: Regole dell'albero (max_depth = 3).

6. Diagnostica dei Modelli e Importanza Feature

Comportamento e Diagnostica:

- **Underfitting:** Escluso. I modelli lineari e l'albero catturano bene i pattern base ($\approx 80\%$ accuratezza).
- **Overfitting:** Rilevato nella Rete Neurale (MLP). Raggiunge il 91% sul train ma cala al 73.6% sul test, imparando a memoria i dati.

L'utilità del Cluster:

- Anche in presenza di overfitting, la feature di clustering funge da forte segnale d'aiuto per l'MLP, guidando l'apprendimento verso i veri clienti a rischio e aumentando la Recall di test di oltre 15 punti.




Grafico: Top 10 feature più importanti. Spiccano il contratto mensile, la tenure e la fibra ottica.

7. Conclusioni e Sviluppi Futuri

Lezioni principali:

- **Clustering k-Means:** Identifica due profili commerciali chiari e coerenti.
- **Valore Modello Ibrido:** L'inserimento del cluster aumenta drasticamente la sensibilità (Recall +15.5%) dell'MLP nell'intercettare l'abbandono.
- **Trasparenza vs Performance:** L'albero di decisione è white-box ed immediatamente interpretabile; la rete neurale MLP è black-box e soffre di overfitting ma offre margini di ottimizzazione migliori.

Sviluppi Futuri (Miglioramento dei Modelli):

- **Regolarizzazione dell'MLP:** Introdurre penalizzazione L2 o dropout per contrastare l'overfitting.
- **Bilanciamento:** Applicare tecniche come SMOTE per compensare lo sbilanciamento del dataset (3:1).



Università
degli Studi di
Messina

Grazie per l'attenzione!

Massimo Mantineo - Matricola: 541924