

Progetto 1: Segmentazione Clienti e Churn Prediction

Spiegazione Semplificata del Progetto

Massimo Mantineo

Matricola: 541924

Università degli Studi di Messina
Corso di Laurea in Informatica

Laboratorio di Intelligenza Artificiale
A.A. 2025/2026



Università
degli Studi di
Messina

1. Di cosa tratta il Progetto e da dove vengono i Dati?

Il Dataset:

- Usiamo il dataset reale **Telco Customer Churn di IBM**.
- Contiene i profili commerciali e anagrafici di 7043 clienti.

L'obiettivo:

- Capire quali clienti rischiano di abbandonare l'operatore (**Churn Prediction**) per intervenire in tempo.

La sproporzione delle classi:

- Le classi sono sbilanciate (3:1): 73.4% fedeli e 26.6% che abbandonano.





Grafico: Chi se ne va (Yes Churn) ha una permanenza bassissima (mediana ≈ 10 mesi).

2. Come abbiamo sistemato i Dati? (Preprocessing)



3. Segmentazione dei Clienti (Clustering k-Means)

Scelta del numero di Cluster (k):

- **Inertia (Gomito):** Indica compattezza dei gruppi. La curva flette a $k = 2$ e $k = 3$.
- **Silhouette Score:** Indica separazione. Raggiunge il suo **massimo assoluto a $k = 2$ (0.2946)**.




Grafico: Gomito e Silhouette.

I due profili commerciali ($k = 2$):

Cluster 0: Fedeli a basso consumo

- **Spesa / Mesi:** 21.08 \$ / 30.5 mesi (medie).
- **Contratto:** Pluriennali (stabili).
- **Tasso di Churn:** 7.40% (estremamente sicuro).

Cluster 1: Ad alta spesa e volatili

- **Spesa / Mesi:** 76.84 \$ / 32.9 mesi (medie).
- **Contratto:** Mensile flessibile.
- **Tasso di Churn:** 31.83% (rischio 4 volte superiore).

4. I Modelli di Predizione e gli Scenari

Abbiamo addestrato 3 classificatori con filosofie differenti:

1. Regressione Logistica

Baseline lineare.

Calcola l'impatto delle caratteristiche del cliente e le mappa in una probabilità tramite la curva **Sigmoide**.

2. Albero di Decisione

Modello White-Box.

Crea regole logiche gerarchiche (IF-THEN). Trova gli split migliori per massimizzare l'omogeneità dei gruppi (Gini).

3. MLP (Rete Neurale)

Modello Black-Box.

Rete a strati densi per catturare relazioni complesse ed effetti combinati delle caratteristiche.

I due scenari di addestramento messi a confronto:

Scenario A: Senza Cluster

I modelli usano solo le feature originali del dataset (dati commerciali e anagrafici preelaborati).

Scenario B: Con Cluster (Modello Ibrido)

Aggiungiamo all'input il **cluster di appartenenza (0 o 1)** di *k*-Means, per valutarne il valore informativo.

4.1 Come Funzionano i Modelli? (Concetti Chiave)

Ogni classificatore elabora i dati con una logica differente:

Regressione Logistica

Logica Probabilistica:

- Pesa l'influenza di ciascuna variabile sul rischio di abbandono.
- Calcola una probabilità complessiva che il cliente se ne vada.
- Classifica come "a rischio" se supera la soglia del 50%.

Albero di Decisione

Logica a Regole (IF-THEN):

- Divide ricorsivamente i dati ponendo domande basate su soglie (es. $tenure \leq 10$ mesi).
- Cerca lo split che crea i gruppi più omogenei e separati.
- Struttura visiva trasparente e intuitiva per le scelte aziendali.

Rete Neurale (MLP)

Logica Multi-Strato:

- Simula una rete di neuroni organizzata in vari livelli.
- Combina le variabili per apprendere relazioni non lineari complesse.
- Regola continuamente le connessioni per correggere gli errori di stima.

5. Tabella dei Risultati

Confronto tra lo Scenario **Senza Cluster** e lo Scenario **Con Cluster** (aggiunto come feature).

Tabella: Accuratezza, Recall (Richiamo dei clienti a rischio) e AUC su Train e Test.

Modello	Feature Scenario	Accuracy		Recall		AUC	
		Train	Test	Train	Test	Train	Test
Logistic Regression	Senza Cluster	0.8053	0.8062	0.5485	0.5588	0.8492	0.8422
Logistic Regression	Con Cluster	0.8051	0.8055	0.5485	0.5588	0.8492	0.8423
Decision Tree	Senza Cluster	0.8023	0.7942	0.5612	0.5401	0.8476	0.8267
Decision Tree	Con Cluster	0.8023	0.7942	0.5612	0.5401	0.8476	0.8267
Multi-Layer Perceptron (MLP)	Senza Cluster	0.9143	0.7495	0.7813	0.4278	0.9656	0.7844
Multi-Layer Perceptron (MLP)	Con Cluster	0.9104	0.7360	0.9097	0.5829	0.9722	0.7846

- **Cosa notare:** L'MLP con l'aggiunta del cluster fa salire la Recall di Test del **+15.5%** (da 0.4278 a 0.5829).

6. Interpretazione dell'Albero di Decisione

Significato dei Colori:

- **Nodi Blu:** Clienti fedeli (No Churn).
- **Nodi Arancioni:** Clienti a rischio (Yes Churn).
- **Intensità:** Colori più scuri indicano decisioni più nette e omogenee.

Le 3 Regole Chiave individuate:

- **1. Tipo di Contratto:** È lo split iniziale più importante. I contratti mensili sono molto più instabili.
- **2. Mesi di permanenza (Tenure):** Chi ha un contratto mensile ed è iscritto da poco è nella fascia a rischio massimo.
- **3. Servizi & Spesa:** Fibra ottica e costi mensili alti aumentano la volatilità dei clienti.




Grafico: Regole dell'albero.

7. Diagnostica dei Modelli e Indizi Chiave

Capire gli Errori dei Modelli:

- **Underfitting (Studiare troppo poco):** Non è il nostro caso. I modelli sono in grado di catturare le regole di base dei dati ($\approx 80\%$ di accuratezza).
- **Overfitting (Studiare a memoria):** Colpisce la Rete Neurale (MLP). Ottiene il 91% di risposte corrette in addestramento, ma cala al 73.6% su dati nuovi perché "impara a memoria" i dettagli.

L'utilità reale del Cluster:

- Anche se la Rete Neurale soffre di overfitting, l'uso del **Cluster** come indizio extra la guida nel focalizzarsi sui clienti giusti: la sua capacità di trovarli (Recall) sale del **+15.5%** (da 42.8% a 58.3%).




Grafico: I 10 indizi più importanti. I mesi di permanenza (*tenure*) e la fibra ottica guidano la decisione.

8. Cosa impariamo da questo Progetto?

Le Lezioni del Progetto:

- **Utilità del Clustering:** Il k -Means ha estratto profili commerciali chiari (fedeli a bassa spesa vs. volatili ad alta spesa) utili per definire strategie aziendali mirate.
- **Valore del Modello Ibrido:** Inserire il Cluster come feature ha potenziato la Rete Neurale (MLP), aumentandone la Recall sul test del **+15.5%** (scovando molti più clienti in partenza).
- **Scelta del Modello:** L'Albero di Decisione è preferibile per la trasparenza aziendale delle sue regole di split, mentre l'MLP ha potenzialità maggiori ma richiede controllo sull'overfitting.

Sviluppi Futuri (Miglioramento dei Modelli Esistenti):

- **Regolarizzazione dell'MLP:** Introdurre penalizzazioni (L2) o arresto anticipato per ridurre l'overfitting e stabilizzare l'accuratezza di test.
- **Bilanciamento dei Dati:** Gestire lo sbilanciamento delle classi (es. tramite tecniche come SMOTE) per addestrare i modelli su campioni di churn più equilibrati.

Grazie per l'attenzione!