

Progetto 1: Segmentazione Clienti e Churn Prediction

Spiegazione Semplificata del Progetto

Massimo Mantineo

Matricola: 541924

Università degli Studi di Messina
Corso di Laurea in Informatica

Laboratorio di Intelligenza Artificiale
A.A. 2025/2026



Università
degli Studi di
Messina

1. Di cosa tratta il Progetto?

L'obiettivo:

- Capire quali clienti stanno per abbandonare la compagnia telefonica (**Churn Prediction**).
- Aiutare l'azienda a intervenire prima che il cliente se ne vada.

Il problema principale dei dati:

- Le classi sono **sbilanciate** (3:1).
- Ci sono molti clienti fedeli (73.4%) e pochi che abbandonano (26.6%).




Grafico: La maggior parte dei clienti non abbandona (No Churn).

2. Come abbiamo ripulito i Dati?

- **Dati Mancanti:** Riempite 11 celle vuote in **TotalCharges** con '0.0' (erano clienti appena registrati con *tenure* = 0).
- **One-Hot Encoding:** Tradotto le parole (es. contratti **Mensile, Annuale**) in numeri '0' e '1' (bandierine) perché il computer legge solo numeri.
- **Standardizzazione:** Riportato le variabili numeriche ad armi pari (stessa scala), altrimenti i numeri grandi (come i costi totali) avrebbero dominato su quelli piccoli (come i mesi di permanenza).




Grafico: Chi ha pochi mesi di contratto (tenure bassa) tende ad abbandonare di più.

3. Dividiamo i clienti in Gruppi (Clustering)

Usiamo il k -Means per trovare gruppi di clienti simili, senza usare l'etichetta di Churn.

- Scelto $k = 2$ (Silhouette Score massimo = **0.2946**).

Chi sono i 2 Cluster trovati?

- **Cluster 0** (Fedeli - Spesa Bassa):
 - Spesa media: 21.08 \$. Contratti lunghi.
 - Churn rate reale bassissimo: **7.40%**.
- **Cluster 1** (A rischio - Spesa Alta):
 - Spesa media: 76.84 \$. Contratti mensili.
 - Churn rate reale molto alto: **31.83%**.




Grafico: La scelta di $k = 2$ bilancia l'Inertia (gomito) e la Silhouette.

4. I Modelli di Predizione (Classificazione)

Abbiamo addestrato 3 modelli per capire se un cliente abbandonerà:

1. Regressione Logistica

Il modello di riferimento semplice.

Usa la funzione **Sigmoide** per trasformare i calcoli in una probabilità compresa tra 0 e 1.

2. Decision Tree

Ragiona a regole ("Sì o No").
Impostato con profondità massima a **5** per evitare che impari a memoria le risposte (regolarizzazione).

3. MLP (Rete Neurale)

Modello complesso con layer nascosti.

Usa l'attivazione **ReLU** dentro la rete per apprendere relazioni complesse e la **Sigmoide** in uscita per decidere.

5. Tabella dei Risultati

Confronto tra lo Scenario **Senza Cluster** e lo Scenario **Con Cluster** (aggiunto come feature).

Tabella: Accuratezza, Recall (Richiamo dei clienti a rischio) e AUC su Train e Test.

Modello	Feature Scenario	Accuracy		Recall		AUC	
		Train	Test	Train	Test	Train	Test
Logistic Regression	Senza Cluster	0.8053	0.8062	0.5485	0.5588	0.8492	0.8422
Logistic Regression	Con Cluster	0.8051	0.8055	0.5485	0.5588	0.8492	0.8423
Decision Tree	Senza Cluster	0.8023	0.7942	0.5612	0.5401	0.8476	0.8267
Decision Tree	Con Cluster	0.8023	0.7942	0.5612	0.5401	0.8476	0.8267
Multi-Layer Perceptron (MLP)	Senza Cluster	0.9143	0.7495	0.7813	0.4278	0.9656	0.7844
Multi-Layer Perceptron (MLP)	Con Cluster	0.9104	0.7360	0.9097	0.5829	0.9722	0.7846

- **Cosa notare:** L'MLP con l'aggiunta del cluster fa salire la Recall di Test del **+15.5%** (da 0.4278 a 0.5829).

6. Regole dell'Albero di Decisione

L'Albero di Decisione è facile da interpretare (trasparente).

- Lo split principale avviene sulla variabile **Contract_Month-to-month** (Contratto mensile).
- Se il contratto è mensile, la variabile successiva più importante è la **tenure** (permanenza).
- Se il cliente ha un contratto mensile ed è iscritto da poco tempo, la probabilità di abbandono è altissima.




Grafico: Struttura a quiz Sì/No del Decision Tree.

7. L'Overfitting e l'importanza del Cluster

Cos'è l'Overfitting? (Visto nell'MLP)

- L'MLP ha memorizzato i dati di Train (91.0)

L'utilità del Cluster:

- La colonna Cluster 1 risulta una delle feature più importanti per l'albero e per la rete neurale.
- Aiuta la rete MLP a trovare i clienti reali a rischio di abbandono (Recall a 0.5829).




Grafico: Le variabili più importanti (tipo contratto, mesi, e il nostro Cluster).

8. Cosa impariamo da questo Progetto?

Conclusioni Chiave:

- Il **Clustering** (non supervisionato) ha diviso i clienti in due profili commerciali chiari (spesa bassa e fedeli vs. spesa alta e volatili).
- Inserire questo profilo come feature ha aiutato la **Rete Neurale (MLP)** a identificare molti più clienti a rischio di abbandono sul Test Set (Recall +15.5%).

Sviluppi Futuri per migliorare:

- Utilizzare tecniche per bilanciare i dati (SMOTE) ed evitare l'overfitting dell'MLP.
- Provare modelli ensemble come il **Random Forest**.

Grazie per l'attenzione!